

HYDROMIND

INDUSTRY 4.0 · MANTENIMIENTO PREDICTIVO

SOLUCIÓN IMPLEMENTADA

JUAN PABLO GONZÁLEZ BLANDÓN

19 de Mayo, 2026

Agenda de la Presentación

01 Objetivo General y Objetivos Especificos del Proyecto

02 Diagrama de Bloques de la Solución

03 Pre-tratamiento de Datos y Matriz X, Dimensiones de Entrenamiento, Prueba y Validación

04 Algoritmos Implementados y Resultados Finales

05 Conclusiones y Trabajo Futuro

Objetivo General y Objetivos Especificos


Desarrollar un sistema de mantenimiento predictivo inteligente para sistemas hidráulicos industriales mediante modelos híbridos de Machine Learning.

Evaluar la viabilidad técnica de reducir las ventanas de tiempo de predicción.

Determinar el subconjunto de variables con mayor poder predictivo por componente.

Evaluar la eficacia de un sistema de mantenimiento predictivo mediante el despliegue de modelos especializados por componente.

02 Diagrama de Bloques – Propuesta de Solución



Dimensiones de la Matriz X – Entrenamiento, Prueba y Validación

Gold / Matrices X

X_silver
2,205 × 102

Y (5 targets)
2,205 × 5

División por Target

70%

15%

15%

Entrenamiento

Validación

Test

2,205 ciclos totales
(dataset ZeMA)

CV: StratifiedKFold (k=5)

Target	X_gold	Entren. (70%)	Val. (15%)	Test (15%)
cooler_condition	2,205 × 1	1,543 × 1	331 × 1	331 × 1
valve_condition	2,205 × 14	1,543 × 14	331 × 14	331 × 14
internal_pump_leakage	2,205 × 11	1,543 × 11	331 × 11	331 × 11
hydraulic_accumulator	2,205 × 27	1,543 × 27	331 × 27	331 × 27
stable_flag	2,205 × 19	1,543 × 19	331 × 19	331 × 19

División estratificada: 70% entrenamiento · 15% validación · 15% test (stratify=Y)

Decision Tree


Target:
Cooler Condition

Parámetros:
max_depth=3

¿Por qué?

Un árbol de profundidad 3 es suficiente con 1 feature (CE_mean). Interpretatable físicamente.

Structure of the Decision Tree Classifier for Cooler Condition



Random Forest

Target:
Accumulator & Stable Flag

Parámetros:
n_estimators, max_depth,
min_samples_leaf, max_features, class_weight

¿Por qué?

Robusto ante outliers y clases desbalanceadas. GridSearchCV 144 combinaciones.


SVM (RBF)

Target:
Pump Leakage & Valve

Parámetros:
C, gamma, kernel, class_weight,
decision_function_shape

¿Por qué?

Fronteras no lineales complejas. Mejor performance en estados solapados (PCA).



XGBoost

Target:
Comparación (benchmark)

Parámetros:
n_estimators, lr, max_Depth, subsample,
colsample_bytree, eval_metric

¿Por qué?

Boosting gradient: alta capacidad en datos tabulares. Referencia para comparación.

Estrategia de optimización: GridSearchCV (StratifiedKFold, k=5, scoring=f1_weighted) sobre el conjunto de entrenamiento. Evaluación final sobre test set no visto durante entrenamiento.

06 Resultados Finales – F1-Score por Componente

0.99

F1 Test · DT (depth=3)

Cooler Condition

0.99

F1 Test · Best RF (tuned)

Hydraulic Accum.

≥ 0.97

F1 Test · Best SVM (RBF)

Pump Leakage

≥ 0.96

F1 Test · Best SVM (RBF)


Valve Condition

0.99

F1 Test · Best RF (k=300)

Stable Flag

F1-Score Weighted por Componente




Hallazgos Clave


- ✓ Cooler: Decision Tree (1 feature), 99% — clasificación perfecta con umbral simple en CE_mean
- ✓ Stable Flag: RF detecta 100% de precisión en ciclos inestables, recall=1.00 en ciclos estables
- ✓ Accumulator: RF tuned (300 árboles) logra 0.99 F1, supera XGBoost (0.97) y SVM (0.95)
- ⚠ Valve & Pump: SVM RBF estados solapados, sin embargo grandes resultados con F1-Score superiores al 97% y 96%

Resultados Finales – Matriz de confusion


Pump Leakage




Valve Condition




Stable Flag



Cooler




Acumulator






Resultados Finales – Errores

Cooler Condition — Cycle 220 | True: 20 → Predicted: 3
Top 3 features most responsible for the error



Hydraulic Accumulator — Cycle 167 | True: 130 → Predicted: 90
Top 3 features most responsible for the error




Resultados Finales – Comparación con el Estado del Arte

Métrica / Dimensión	Enfoque Deep Learning(CNN-1D / LSTM)[Ref: Repositorio PyTorch / Sensors 2020]	Enfoque Estadístico Global / Multitarget(Stacking / Reglas)[Ref: Noura et al., 2024 / Helwig]	Solución HydroMind(Pipeline Medallion + Modelo por Componente)
Volumen de Datos / Feature Matrix X	Alta densidad: Procesamiento de ráfagas crudas de series de tiempo completas (miles de puntos por ciclo de 60s).	Intermedio: Agrupamiento global de variables sin una estructura modular de datos.	Optimizado (Capa Gold): Reducción de miles de puntos a 102 características (Silver), refinadas mediante RFE por componente.
Precisión Promedio F1-Score	• CNN-1D: 0.95 - 0.98 • LSTM: 0.85 - 0.88 (<i>Sufre de Overfitting en Test</i>)	Enfoques globales logran un F1 promedio general entre 0.92 y 0.96 .	Sobresaliente: F1-Score > 0.97 de manera consistente en los 5 targets independientes.
Tiempo de Entrenamiento (Costo)	Alto: Minutos/Horas por época. Requiere infraestructura dedicada (GPU / CUDA).	Bajo: Segundos/Minutos en CPU, pero con rigidez estructural ante cambios de sensores.	Muy Bajo: Entrenamiento aproximado en minutos (< 2) directamente sobre CPU utilizando GridSearchCV.
Tiempo de Inferencia (Latencia)	Alto para Edge: > 150 - 300 ms por ciclo (Complejidad por capas de atención o convoluciones temporales).	Bajo: < 20 ms por ciclo, pero con menor resolución predictiva en estados de degradación sutil.	Ultra-Bajo (Tiempo Real): < 10 milisegundos por ciclo de inferencia, ideal para hardware embebido local.
Interpretabilidad (Feature Importance)	0% (Caja Negra): No hay métrica numérica de qué sensor causó la predicción debido a las transformaciones no lineales.	Media: Coeficientes de correlación global lineal, incapaces de aislar componentes individuales.	100% Medible: Importancia de características explícita (ej: <i>Cooler</i> se explica al 100% numéricamente por la variable CE_mean).

Noura, H. N., Chu, T., Allal, Z., Salman, O., & Chahine, K. (2024). A comparative study of ensemble methods and multi-output classifiers for predictive maintenance of hydraulic systems. *Results in Engineering*, 24, 102900

<https://github.com/France1/predictive-maintenance-pytorch>

Resultados Finales – Ventanas de tiempo



Ventaja Temporal: Diagnóstico y alerta temprana **15 segundos antes** de finalizar el ciclo estándar (reducción del 25% en tiempo de respuesta).

Eficiencia de Datos: Reducción del **25% en el volumen de datos crudos** a procesar en las capas *Bronze* y *Silver*, disminuyendo drásticamente el costo de almacenamiento y cómputo en la planta.

Resultados Finales – Dashboard

Hydraulic Sensor Analysis

Analizando ciclos completos de 45s. Actualización cada 45s.

Drag o selecciona .txt


Iniciar Procesamiento

Detener


Sensores cargados:

CE CP FS1 SE TS3 TS1
TS4 FS2 VS1 TS2 PS4
EPS1 PS1 PS2 PS3 PS5
PS6

CE – 1 Hz (60 muestras/ciclo)



CP – 1 Hz (60 muestras/ciclo)



FS1 – 10 Hz (600 muestras/ciclo)

Diagnóstico en tiempo real

Estabilidad de señales

✓ Señales estables

Estado del sistema

● Falta severa detectada

Componentes

🔧 Cooler

⚠️ Eficiencia reducida (20%)

🔧 Válvula

⚠️ Falta pequeña (90%)

💧 Bomba

✓ Sin fuga

🔋 Acumulador

● Falta severa (100 bar)

Último ciclo: #1

CONCLUSIONES



Resultados sólidos

La implementación de **un pipeline Medallion modular** permitió transformar datos crudos de alta frecuencia en indicadores predictivos precisos, logrando un **F1-Score < 0.97** en los cinco componentes críticos.



Innovación Operativa

El análisis de sensibilidad temporal demostró que es posible reducir la ventana de inferencia a **45 segundos**, garantizando un diagnóstico fiable con un **25% menos de carga computacional** y **15 segundos de ventaja en alerta temprana**.



Transparencia y Física

A diferencia de modelos "caja negra" (Deep Learning), nuestra especialización por componentes mediante RFE proporcionó **interpretabilidad física**, permitiendo a los ingenieros comprender la causa raíz de la degradación (ej. relación directa entre temperatura y eficiencia del Cooler).

TRABAJO FUTURO



Despliegue en Edge Computing

Portabilidad del pipeline hacia dispositivos embebidos de bajo consumo (FPGA o microcontroladores industriales) para monitoreo on-premise sin depender de la nube.



Detección de Anomalías no Supervisada

Implementar algoritmos no supervisados para detectar fallos nuevos o "desconocidos" que no están presentes en el dataset de entrenamiento actual.

HYDROMIND

INDUSTRY 4.0

Gracias

¿Preguntas?